

LSTM vs Transformer Encoder for Text Classification (AG News)

Team: 장지훈 (ETRI School, 02521122) · Deep Learning 2, 2026

1. Introduction

본 프로젝트는 AG News 4-class 뉴스 주제 분류에서 recurrent 구조인 LSTM과 self-attention 구조인 Transformer Encoder를 동일한 조건으로 비교한다. 두 모델은 모두 from scratch로 학습한다. research question은 "데이터, preprocessing, vocabulary, sequence length, 학습 예산을 동일하게 통제했을 때 두 구조가 성능, 수렴, data efficiency, 오분류 양상에서 어떻게 다른가"이다. 목표는 높은 정확도 자체가 아니라 차이의 원인을 설명하는 것이다. LSTM과 Transformer는 sequence encoding에서 가장 널리 쓰인 두 구조이며, 동일 과제에서의 통제된 직접 비교는 각 구조의 강점과 약점을 드러낸다.

2. Dataset

출처는 HuggingFace의 AG News single source이며, 4개 class(0 World, 1 Sports, 2 Business, 3 Sci/Tech)로 구성된다. test set은 최종 평가에만 사용하고, validation set은 training set의 10%를 분리해 구성했다(seed 42).

Split	샘플 수
Train	108,000
Validation	12,000
Test	7,600

Class	Train	Test
World	26,991	1,900
Sports	26,966	1,900
Business	27,100	1,900
Sci/Tech	26,943	1,900

Preprocessing은 두 모델에 동일하게 적용했다. 단어 단위 tokenization(소문자화) 후, vocabulary는 training set에서만 구축했다(상한 20,000, minimum frequency 2, padding token과 unknown token 포함). 각 문장은 최대 길이 128로 자르거나 padding했고, padding 위치는 masking으로 무시했다. training set의 고유 단어는 67,575종이며, 빈도 상위 20,000종으로 전체 token 출현의 97.3%를 덮는다. 따라서 unknown token으로 처리되는 비율은 약 2.7%로 작다.

Label indexing은 혼한 오류 지점이다. raw CSV 버전은 label이 1에서 4이지만 HuggingFace 버전은 0에서 3이라 cross-entropy loss가 요구하는 0-based index와 바로 호환된다. single source만 사용해 이 혼선을 피했다.

3. Models

두 모델의 공유 골격은 동일하다. embedding(차원 128) → encoder → masked mean pooling → linear layer(출력 4) 순서이며, loss는 cross-entropy를 사용한다. 두 모델은 가운데 encoder만 다르다. 이 통제가 비교의 핵심이며, 성능 차이를 구조 차이로 귀속할 수 있게 한다.

구성	LSTM	Transformer Encoder
Embedding dimension	128	128
Encoder	bidirectional LSTM, 2 layers, hidden size 128	2 layers, 4 attention heads, feed-forward network dimension 256, sinusoidal positional encoding

Output dimension	256 (bidirectional)	128 (model dimension)
Pooling / Loss	masked mean pooling / cross-entropy	masked mean pooling / cross-entropy
Trainable parameters	3,220,484	2,825,476

embedding(약 256만 parameters)이 양쪽에서 공통으로 지배적이므로, 총 parameter 규모는 약 14% 차이로 비교 가능한 수준이다.

Implementation 세부는 다음과 같다. padding token은 index 0으로 고정하고 embedding의 padding index로 지정해 그 vector가 학습되지 않게 했다. pooling과 self-attention은 padding 위치를 masking으로 무시한다. 두 모델 모두 동일한 masked mean pooling을 사용해, pooling 방식이 비교의 교란 요인이 되지 않도록 했다.

4. Experiments

학습 설정은 Adam optimizer, learning rate 0.001, batch size 64, 최대 8 epochs, dropout 0.1, seed 42이다. model selection은 validation 성능 기준 best checkpoint로만 수행했고, test set은 최종 1회만 평가했다. 학습 환경은 Mac MPS이다.

Main comparison은 위 설정으로 두 모델을 학습한다. Ablation은 data efficiency를 측정하기 위해 training set을 5%, 25%, 50%, 100%로 줄여 두 모델을 학습한다. 이때 vocabulary는 전체 training set에서 한 번 구축해 모든 비율에 고정 재사용하고, 부분 추출은 class 비율을 유지(stratified)하며 seed를 고정한다. validation set과 test set은 항상 전체를 사용한다.

평가 지표는 accuracy, macro F1-score, training/validation loss curve, confusion matrix이다. 공정 비교를 위해 split, tokenizer, vocabulary, 최대 길이, pooling, optimizer, learning rate, batch size, epoch 수, seed를 두 모델에 동일하게 고정했다. 유일한 변수는 encoder 구조다.

5. Results

Model	Test accuracy	Test macro F1-score
LSTM	0.833	0.835
Transformer	0.910	0.909

Transformer가 약 7.7 percentage point 앞선다. 비슷한 parameter 규모에서의 차이다.




Figure 1. Training and validation loss curves (left: LSTM, right: Transformer).

학습 곡선이 성능 차이의 직접 증거다. LSTM은 training loss가 0.035까지 감소하는 동안 validation loss가 0.54에서 약 2.0으로 증가한다. 전형적인 overfitting이다. Transformer는 validation loss가 약 0.28에서 0.33으로 평탄하게

유지되어 overfitting이 거의 없고, 첫 epoch에 이미 88% 정확도로 빠르게 수렴한다. validation 기준 best checkpoint가 overfitting 이전 시점(epoch 2)을 저장해 LSTM의 최종 성능을 확보했다.




Figure 2. Confusion matrices (row: true label, column: predicted label).

혼동 양상은 두 모델에서 다음과 같이 나타난다. LSTM에서는 Business가 주로 Sci/Tech로 오분류되고(258건), Sci/Tech도 주로 Business로 오분류되어(154건) 두 class의 상호 혼동이 가장 크다. World와 Sports는 오류 분포가 서로 비슷하며, 둘 다 주로 Business와 Sci/Tech로 오분류된다. 결과적으로 LSTM은 모든 class에서 상당한 오류를 내어 오류가 전반에 퍼져 있다. Transformer에서는 오류가 거의 Business와 Sci/Tech의 경계에 집중되고(Business를 Sci/Tech로 147건, Sci/Tech를 Business로 138건), Sports는 거의 완벽하며(오분류 38건) World도 깨끗하다.

공통점은 두 모델 모두 Business와 Sci/Tech를 가장 많이 혼동한다는 것이다. 두 class가 기업, 기술, 시장 관련 어휘를 공유하기 때문이며, sequence length가 아니라 의미 중첩이 혼동의 원인이다. class별로 보면 Transformer는 Sports와 World에서 특히 강하고 Business와 Sci/Tech에서만 약하다. LSTM은 Sports와 World에서도 Transformer만큼 강하지 않아, 어휘가 뚜렷한 class에서조차 오류가 적지 않다.




Figure 3. Data-efficiency ablation. Test accuracy versus training set size.

Training data	LSTM	Transformer	Gap
5% (5,399)	0.727	0.798	+0.071
25% (26,998)	0.846	0.875	+0.029
50% (53,999)	0.833	0.897	+0.064

100% (108,000)

0.833

0.910

+0.077

Transformer는 데이터가 늘수록 정확도가 단조롭게 향상된다. LSTM은 25%에서 0.846으로 정점을 기록한 뒤 정체하며, 데이터를 더 늘려도 overfitting 때문에 향상되지 않는다. 즉 LSTM은 약 25% 지점에서 성능이 saturation되어 추가 데이터를 활용하지 못하고, Transformer는 데이터에 따라 안정적으로 scaling된다. Transformer가 모든 구간에서 앞서므로, Transformer가 LSTM보다 더 많은 학습 데이터를 요구한다는 사전 가설(data efficiency가 더 낮다는 가설)은 본 과제에서 기각되었다. AG News는 비교적 쉬운 과제라 5,400개 규모에서도 Transformer가 충분히 일반화했다.

학습 효율에서도 차이가 있었다. Mac MPS에서 epoch당 학습 시간은 Transformer가 약 47초로 LSTM의 약 56초보다 짧았다. self-attention은 위치 간 연산을 병렬화할 수 있는 반면 LSTM은 token을 순차적으로 처리하기 때문이다. 따라서 Transformer는 정확도와 학습 속도 양쪽에서 앞섰다.

종합하면, 두 모델의 성능 차이는 sequence order 처리 능력(다음 절에서 보듯 이 과제는 order를 거의 활용하지 않는다)이 아니라 generalization과 overfitting의 차이에서 비롯한다.

6. Failure Analysis

본문 요약	정답	LSTM 예측	Transformer 예측	추정 원인
Some People Not Eligible to Get in on Google IPO	Sci/Tech	Business	Business	기업의 IPO라 금융과 기술의 경계가 모호함
Intel to delay product aimed for high-definition TVs	Business	Sci/Tech	Sci/Tech	어휘는 기술이지만 label은 사업 영향, 두 모델 모두 높은 확신으로 오분류
Teenage T. rex's monster growth	Sci/Tech	Business	Sci/Tech	명백한 과학 기사인데 LSTM만 낮은 확신으로 오분류
IBM to hire even more new workers	Sci/Tech	Business	Sci/Tech	고용 기사라 경계가 모호, Transformer만 정확히 분류
Prediction Unit Helps Forecast Wildfires	Sci/Tech	Sci/Tech	Sports	Transformer의 드문 오분류

카테고리별 개수는 두 모델 모두 오분류 428건, LSTM만 오분류 841건, Transformer만 오분류 259건이다. LSTM 단독 오류가 약 3.2배 많아 정확도 차이를 뒷받침한다. 두 모델이 함께 오분류한 사례의 61%는 정답이 Business 또는 Sci/Tech다. 이들은 label 자체가 모호한 경계 사례로, 모델의 결함이라기보다 과제의 class 중첩에서 비롯한다.

확신도 양상도 다르다. 공통 오분류는 종종 높은 확신을 동반한다. 예를 들어 Intel 기사에서는 두 모델 모두 0.98 이상의 확신으로 오분류했다. 모호한 경계에서의 overconfidence다. 반면 LSTM 단독 오류는 0.50에서 0.59 수준의 낮은 확신을 동반하는 경우가 많다. 모델이 스스로도 불확실한 상태에서 오분류한 것으로, robustness 부족을 시사한다. 요약하면 두 모델은 서로 다른 양상으로 실패한다.

7. Extension: Transformer Mechanism Analysis

계획한 세 가지 메커니즘 분석을 모두 수행했다. positional encoding 실험만 추가 학습이 필요하고, 나머지는 학습된 모델을 그대로 사용한다.

첫째, positional encoding on/off 실험이다. positional encoding을 제거한 Transformer를 동일 조건으로 다시 학습한 결과, test accuracy는 0.910에서 0.911로 사실상 변하지 않았다(차이 -0.001). self-attention은 positional encoding이 없으면 순서 정보가 없는 set encoder가 된다. 그럼에도 정확도가 동일하다는 것은, AG News가 단어 순서보다 어휘 출현이 결정적인 bag-of-words 성격을 의미한다. 이 과제에서 Transformer의 순서 주입 부품은 불필요하다.

둘째와 셋째는 gradient saliency와 attention weight를 통한 token importance 분석이다. 동일한 Sports 기사에 대해 두 모델이 어느 token을 근거로 판단하는지 비교했다.




Figure 4. Token importance on a Sports example (true label: Sports). Left: LSTM gradient saliency. Center and right: Transformer gradient saliency and attention weight.

LSTM은 주제와 무관한 단어 "giddy"에 가장 큰 importance를 부여하고 이 기사를 Sci/Tech로 오분류했다. 반면 Transformer는 "phelps", "seconds", "medley", "400" 같은 주제 token에 importance를 분산했고, gradient saliency와 attention weight가 같은 경향을 보이며 기사를 정확히 Sports로 분류했다. 즉 Transformer는 판단 근거를 여러 주제 token에 분산하는 반면, LSTM은 특정 token 하나에 과도하게 의존할 수 있다. 이는 정확도 차이의 token 수준 원인을 보여준다. 다만 gradient saliency와 attention weight가 완전히 일치하지는 않으므로, attention weight를 곧바로 설명으로 등치할 수는 없다.

8. Conclusion

- 동일 조건에서 Transformer가 LSTM보다 분명히 우수하다(test accuracy 0.910 대 0.833).
- 성능 차이의 원인은 generalization 능력의 차이이다. LSTM은 심하게 overfitting하고 약 25% 데이터 지점에서 saturation되어 추가 데이터를 활용하지 못한다. Transformer는 데이터에 따라 안정적으로 scaling된다.
- 이 과제는 단어 순서가 거의 중요하지 않은 bag-of-words 성격이다. positional encoding 제거가 정확도에 영향을 주지 않았다. 따라서 성능 차이는 순서 처리 능력이 아니라 robustness와 generalization에서 비롯한다.
- Transformer가 더 많은 학습 데이터를 요구한다는 사전 가설은 기각되었다. 모든 데이터 구간에서 Transformer가 앞섰다.
- 한계와 향후 과제로, 결과는 단일 seed 기준이므로 여러 seed로 재확인 필요하다. LSTM의 dropout 등 regularization을 강화하면 성능 차이가 줄어드는지 검증할 가치가 있다. 또한 단어 순서가 중요한 과제(sentiment analysis, natural language inference)에서 positional encoding의 효과를 재검증하고, 단어 순서를 무작위로 섞는 추가 ablation으로 두 구조의 순서 의존성을 더 직접 비교할 수 있다.